CHEN XINGQIANG

杭州，中国
+86 150-0133-4125 ◇ joy6677@outlook.com ◇ github.com/chenxingqiang

求职意向

寻求**全职**职位：**AI 加速器编译器 / 系统软件 · 大语言模型推理系统 · 软硬件协同设计**。

交叉学科背景

理论物理与生物物理训练，贯通计算化学、分子动力学与计算机科学。竞赛：**全国大学生数学建模竞赛国家一等奖**（2012）、**北美大学生数学建模竞赛（MCM）一等奖**（2013）；**CCF 开源 GPU 创新生态赛 GPU 算子优化挑战赛二等奖**（2025）。

教育背景

生物物理学与凝聚态物理博士研究生（结业，学位答辩中） 2014 年 9 月 - 2018 年 7 月
厦门大学，物理与机电工程学院；导师方向：蛋白质动力学与 QM/MM 仿真

理论物理学学士 2010 年 9 月 - 2014 年 7 月
厦门大学，物理与机电工程学院

技能与项目

编程语言：C++、Python（主要）；CUDA、Java、Scala、Go。

编译器 / 工具链：MLIR、LLVM 后端与 ISA 适配、TVM、图划分与算子融合、成本建模、CodeGen、自动调优。

芯片软件 / 验证：Palladium Emulation、GDB 与仿真模型联调、固件与权重映射生成、算子级指标（Cycles/MACs）分析。

推理系统：Transformers、KV-Cache、量化、批处理与调度、Triton 内核、FlashAttention、CUPTI/Perfetto 性能剖析。

平台：PyTorch、TensorFlow、ONNX、Kubernetes；Spark、Flink、Hadoop。

开源与发布（默认位于 `github.com/chenxingqiang`，均可公开验证）：

- **TraceSmith**：跨平台 GPU Profiling & Replay 系统，覆盖 CUDA/ROCm/Metal/MACA/Ascend；C++ 核心 + Python 绑定，已发布至 PyPI。`TraceSmith`
- **YiRage 持久化内核（YPK）**：LLM 超级内核编译器与运行时，多后端（CUDA/CPU/MPS/Ascend/Triton）。`YiRage`
- **JAX-sklearn**：scikit-learn 兼容接口 + JAX 加速，13,058 项测试通过，PyPI 发布。`jax-sklearn`
- **Secret-Learn**：隐私保护机器学习库，覆盖联邦学习／秘密分享／分割学习，PyPI 发布。`Secret-Learn`
- **YouTube-DNN-RecSys**：YouTube 风格召回与排序的 TensorFlow + Spark 实现（60 stars）。`YouTube-DNN-RecSys`
- **Research CLI**：面向科研工作流的命令行 AI 工具，多模型供应商与 MCP 集成。`iechor-research/research-cli`
- **Questions-Gen**：数学竞赛题目生成（Qwen3-14B、GRPO、蒸馏），含 CLI 与 Hugging Face 权重。`GenQuestion`

工作经历

编译器 & 工具链专家，知存算力（Witmem） 杭州，中国
编译器 / *Palladium* 验证 *2025* 年 *12* 月 *10* 日 - 至今

- 负责存算芯片产品线编译器与 Palladium 仿真验证，覆盖模型编译、指令生成、芯片执行及 Emulation 缺陷定位。
- 完成 Palladium 软件 Bring-up：Compiler 输出在仿真器上运行，结合 GDB 在仿真模型、芯片与系统软件层做联合调试。
- 实现 **CIM-MLIR** 异构编译器：PyTorch/TensorFlow/ONNX 经 TOSA/StableHLO 映射至 CPU、GPU 与 CIM，含前端、图划分、硬件后端与运行时。
- 实现代价驱动图划分与 CIMHigh/Mid/Low 三级 IR；用 OR-Tools 分配 Die/L2/L0 资源，生成可烧录 **config.bin**、权重 **map.bin**，以及 GPU PTX 与 LLVM 主机代码。

- 实现跨设备运行时：分设备执行器、统一内存、计算与传输重叠及三级缓冲；提供 C++/Python 接口及延迟、利用率、传输开销统计。
- 实现 **GRC-PIM**：PIM 上基于 drift gating 与 GEMV 复用的残差校准及软判决纠错，投稿 *npj Unconventional Computing*（详见发表论文）。

高级 AI 编译器工程师，亿铸智能
杭州，中国

研发部门 *2022* 年 *9* 月 - *2025* 年 *12* 月

- 主导 **YiRage 持久化内核 (YPK)**：将端到端 LLM 解码编译为单个超级内核；在 Llama2-7B、单卡 A100 上相对 PyTorch eager 基线取得 **1.2×–6.7×** 端到端延迟收益（随 batch 与序列长度变化）。YiRage
- 实现融合算子（RMSNorm+Linear、GQA 等）与持久化执行模型，显著减少内核启动与中间张量往返；batch=1 decode 路径延迟降幅最大。
- 构建调度层并集成 Triton 与 FlashInfer 内核，支持多卡扩展（最高验证 8 卡）与 NVSHMEM 张量。
- 开发图编译与自动调优：内核参数搜索、KV-cache 友好内存布局，降低访存开销。
- 申请 **2 项**发明专利；相关能力交付 **2 个**数据中心客户 PoC。
- 负责公司 SoC 的 LLVM 后端 Target 与复杂指令集适配，推进编译器后端规范化与软件生态建设。
- 搭建模型转换与算子级评估流程：将 TVM、ONNX、MLCommons、TensorFlow/PyTorch 集成入 **YZlite**，统计 Cycles/MACs 等指标并输出多芯片 benchmark；开源工具包与文档 ReRAM-Labs/yzlite。

隐私保护算法工程师，蓝象智联
杭州，中国

IT Group *2022* 年 *1* 月 - *2022* 年 *9* 月

- 构建基于同态加密的联邦学习平台，支撑多家金融机构的跨域建模；在保持隐私约束下相对本地基线提升模型效果，并缩短训练迭代周期。
- 设计多方安全计算协议，用于银行风控模型的联合训练与推理，兼顾协议安全性与通信开销。
- 开源 **Secret-Learn**：sklearn 兼容 API × 联邦学习／秘密分享／分割学习三种模式，JAX 加速，并与 SecretFlow 集成，PyPI 发布。Secret-Learn
- 申请 **3 项**发明专利（均已公开，可检索）：基于秘密分享的纵向联邦线性支持向量分类方法 CN114925786A；随机森林训练方法及装置 CN114997345A；用于联邦学习的数据处理方法及装置 CN115130681A。

T7 算法工程专家，百图生科
北京，中国

算法工程组 *2021* 年 *9* 月 - *2021* 年 *12* 月

- 构建生物信息学工具链与数据平台，统一大规模生物数据的管理、检索与分析流程，支撑序列分析、结构预测与功能注释。
- 搭建蛋白质结构预测模型评估流程（含 AlphaFold 系列），为药物设计提供结构输入。
- 获 **2 项**软件著作权：生信工具自动化平台（登记号 2021SR2004464）、生物医药信息平台（登记号 2021SR1862397）。
- 开源 AlphaFold2 代码解析与学习资源（26 stars）。alphafold2-codecs

高级算法工程师，Yalla 集团 (纽交所: YALA)
杭州，中国

数据中心工程组 *2020* 年 *9* 月 - *2021* 年 *9* 月

- 重构 Yalla 聊天室推荐系统，引入多目标排序；A/B 实验中人均日活跃时长与 7 日留存均取得显著正向（留存 **42%** → **61%**）。
- 构建 Ludo 风控系统，结合实时行为特征与机器学习模型识别异常账号，显著降低恶意退款比例。
- 开发卡牌类游戏 AI（深度强化学习），用于人机对局与匹配填充，提升低峰时段对局体验与留存。

高级算法工程师，格家网络科技
杭州，中国

搜索推荐工程组 *2019* 年 *3* 月 - *2020* 年 *9* 月

- 设计多场景推荐架构，融合协同过滤、深度排序模型与商品知识图谱；线上实验 CTR 与 CVR 均取得两位数相对提升。
- 优化实时推荐链路：特征缓存与召回裁剪，P99 响应控制在 **50ms** 内，支撑大促期间峰值流量。
- 开源 YouTube-DNN-RecSys：YouTube 风格召回与排序的 TensorFlow + Spark 实现（60 stars）。YouTube-DNN-RecSys

机器学习工程师，便利蜂科技
北京，中国

数据工程组 *2017* 年 *3* 月 - *2019* 年 *3* 月

- 构建门店销量预测系统（覆盖 **50+** 门店），引入格点气象与时空特征，降低缺货与滞销率、提升库存周转。
- 开发用户与商品关联分析：在千万级行为数据上打通客户身份与购买记录，支撑个性化推荐。
- 设计商品视觉识别模型（**500+** SKU），用于快速结算场景，缩短收银与排队时间。

研究与实习

蛋白质分子动力学仿真与 QM/MM 模型
厦门大学，中国
(国家自然科学基金项目) *2014* 年 *9* 月 - *2017* 年 *3* 月

- 以 QM/MM 方法开展蛋白质动力学仿真与构象分析，成果发表于 Acta Cryst. D、PLoS ONE、Phys. Rev. E 等（见发表论文）。

液体活检 ct-DNA 试剂盒开发与 DNA 甲基化数据分析
乐普医疗，中国
(研发工程师实习) *2016* 年 *3* 月 - *2017* 年 *3* 月

- 在 TCGA/GEO 公开基因芯片数据上分析约 10,000 例样本，定位 Septin9 基因甲基化位点（结肠癌早期标志物），支撑临床诊断试剂盒的标志物筛选。

获奖与评审

- **国家一等奖**，全国大学生数学建模竞赛（CUMCM），2012 年。
- **一等奖**（Meritorious Winner），北美大学生数学建模竞赛（MCM/COMAP），2013 年。
- 全球**第 6 名**，国际太阳能十项全能竞赛（Solar Decathlon），2013 年。
- 第 **57** 名与第 **32** 名（共 1739 队），IEEE ICDM 全球气象 AI 挑战赛，2018 年。
- **二等奖**，第八届 CCF 开源创新大赛・开源 GPU 创新生态赛常规赛 S1 ・GPU 算子优化挑战赛（CCF/ODTC），2025 年。CCF 公示
- 评委，应用算法最佳实践初审，2021 年。

发表论文

- Chen X. GRC-PIM: A Drift-Gated, GEMV-Reusing Residual Calibrator for Soft-Decision Error Correction in Processing-in-Memory. *npj Unconventional Computing*（投稿中）。
- Cai Y, Su M, Ahmad A, Hu X, Sang J, Kong L, Chen X, Wang C, Shuai J, Han A. Conformational dynamics of the essential sensor histidine kinase WalK. *Acta Crystallographica Section D: Structural Biology*. 2017 Oct 1;73(10):793-803.
- Xia H, Chen X, Chen X, Cheng J, Liu Y, Chen X, Zhang Q, Zou G. Chiral discrimination of amino acid enantiomers based on different interactions with Cu2+. *Sensors and Actuators B: Chemical*. 2018 Jan 1;254:44-51.
- Ahmad A, Cai Y, Chen X, Shuai J, Han A. Conformational dynamics of response regulator RegX3 from Mycobacterium tuberculosis. *PloS one*. 2015 Jul 22;10(7):e0133389.
- Chen Y, Qi H, Li X, Cai M, Chen X, Liu W, Shuai J. Suppressing effect of C a 2+ blips on puff amplitudes by inhibiting channels to prevent recovery. *Physical Review E*. 2016 Aug 15;94(2):022411.

OPEN SOURCE — SYSTEM ARCHITECTURE APPENDIX

Chen Xingqiang · diagrams restyle DS4/BW01 · content from each repo's official architecture + source tree

TRACESMITH
docs/architecture.drawio
include/tracesmith/*

YIRAGE YPK
docs/yirage-architecture.drawio
include/backend/*.h

JAX-SKLEARN
xlearn/_jax/*.py
xlearn/__init__.py

SECRET-LEARN
docs/secret_learn_architecture.drawio
src/secretlearn/

YOUTUBE-DNN
docs/architecture.drawio
src/python + src/scala

RESEARCH CLI
packages/cli + packages/core
modelRouterService.ts

QUESTIONS-GEN
src/QuestionsGenTrainer.py
questions_gen/

STYLE
dark canvas · nested containers · Courier · real paths · no invented layers

TRACESMITH — SYSTEM ARCHITECTURE

GPU Profiling & Replay · C++17 core + pybind11 · source: docs/architecture.drawio · github.com/chenxingqiang/TraceSmith

APPLICATION LAYER

C++ Application
user binary

Python Application
import tracesmith

C++ CLI
cli/main.cpp

Python CLI
python/tracesmith/cli.py

External Tools
Perfetto UI / Chrome

PYTHON BINDINGS

pybind11 module
python/src/bindings.cpp

_tracesmith.so
native extension

python/tracesmith/__init__.py
package API

native

TRACESMITH CORE LIBRARY (C++17) include/tracesmith + src/

CUPTIProfiler
src/capture/cupti_profiler.cpp

MCPTIProfiler
src/capture/mcpti_profiler.cpp

MetalProfiler
src/capture/metal_profiler.mm

AscendProfiler
src/capture/ascend_profiler.cpp

ROCmProfiler
src/capture/rocm_profiler.cpp

BPFTracer
src/capture/bpf_tracer.cpp

MemoryProfiler
src/capture/memory_profiler.cpp

events

RingBuffer SPSC
common/ring_buffer.hpp

Types / TraceEvent
src/common/types.cpp

StackCapture
src/common/stack_capture.cpp

XRayImporter
src/common/xray_importer.cpp

SBTWriter/Reader
src/format/sbt_format.cpp

GPUStateMachine
src/state/gpu_state_machine.cpp

replay

InstructionStream
src/state/instruction_stream.cpp

TimelineBuilder
src/state/timeline_builder.cpp

TimelineViewer
src/state/timeline_viewer.cpp

PerfettoExporter
src/state/perfetto_exporter.cpp

PerfettoProto
src/state/perfetto_proto_exporter.cpp

ReplayEngine
src/replay/replay_engine.cpp

StreamScheduler
src/replay/stream_scheduler.cpp

OperationExecutor
src/replay/operation_executor.cpp

DeterminismChecker
src/replay/determinism_checker.cpp

FrameCapture
src/replay/frame_capture.cpp

GPUTopology
src/cluster/gpu_topology.cpp

MultiGPUProfiler
src/cluster/multi_gpu_profiler.cpp

TimeSync NTP/PTP
src/cluster/time_sync.cpp

NCCLTracker
src/cluster/nccl_tracker.cpp

GDB RSP
src/gdb/rsp_handler.cpp

TracyExporter
src/tracy/tracy_exporter.cpp

GPU BACKENDS & SYSTEM (createProfiler + nsys / mcTracer / xctrace / msprof)

NVIDIA CUDA
CUPTI SDK + nsys

Apple Metal
Metal API + xctrace

MetaX MACA
MCPTI + mcTracer

Huawei Ascend
CANN + msprof

AMD ROCm
roctracer

Linux eBPF
kernel events

libunwind
host stacks

Perfetto SDK
protobuf

OUTPUT FORMATS

trace.sbt
SBT binary

trace.json
Perfetto JSON

trace.perfetto
protobuf

graph.dot
Graphviz

ASCII timeline
terminal

comm matrix
NCCL heatmap

v0.10+ · capture→ring→SBT→state/timeline→replay/export · files from include/tracesmith and src/

YIRAGE (YPK) — SYSTEM ARCHITECTURE

RuntimeFusion × Multi-Backend · source: docs/yirage-architecture.drawio + include/backend/*.h · github.com/chenxingqiang/YiRage

INFERENCE ENGINE (scheduling + KV owner)

- **vLLM** — continuous batch · PagedAttention
- **SGLang** — RadixAttention · extend meta
- **meta** — block_table · seq_lens · SM budget

decode

RUNTIMEFUSION yirage.serving · RF.step(inputs, meta) selects 0..N capsules / decode step

- **RF.step()** — yirage.serving
- capsule
- **FusionCapsule MLP** — gate_up + down yirage.core
- **FusionCapsule seg** — gate_up → down pipeline
- **skip / fallback** — engine native ops

plan

SEARCH & PLAN (offline / warm-up)

- **superoptimize(backend)** — KN/TB graph search
- **FusionPlan / μGraph** — profile + fingerprint verify
- **MuGraph cache** — shape-bucket restore
- **Ray coordinator** — distributed search optional
- **serving tiers** — seed_verify · full_tb · full_tb_ray

PYTHON API & BACKEND MANAGER (C++)

- **PersistentKernel** — python/yirage
- **KNGraph / TBGraph** — transpiler → kernels
- **BackendRegistry** — include/backend/backend_registry.h
- **yirage.core** — Cython runtime
- **KernelExecutor factory** — search + execute same backend

BACKEND IMPLEMENTATIONS include/backend/*.h + include/kernel/{cuda,maca,cpu,mps,ascend}/

- **CUDA** — cuda_backend.h warp 32 nvcc
- **MACA** — maca_backend.h warp 64 mxcc
- **ROCm** — rocm_backend.h AMD GPU
- **MPS** — mps_backend.h Apple GPU
- **Ascend** — ascend_backend.h CANN
- **CPU** — cpu_backend.h OpenMP/MKL
- **Triton** — triton_backend.h DSL
- **NKI** — nki_backend.h SBUF/DMA
- **cuDNN** — cudnn_backend.h
- **MKL** — mkl_backend.h
- **TPU** — tpu_backend.h
- **XPU** — xpu_backend.h
- **MLIR** — mlir_backend.h CPU JIT
- **FPGA** — fpga_backend.h experimental

HARDWARE TARGETS

- **NVIDIA GPU** — Ampere / Hopper
- **MetaX C500/C550** — MACA
- **x86 / ARM CPU** — Intel / AMD / Apple
- **Apple Silicon** — M1–M4
- **Huawei Ascend** — 910 / 910B / 310P
- **AWS Neuron / Intel XPU** — NKI

Engine owns scheduling & KV; RF owns fusion identity per step · BackendRegistry search+execute same backend

JAX-SKLEARN (xlearn) — SYSTEM ARCHITECTURE

drop-in sklearn · files: xlearn/__init__.py + xlearn/_jax/*.py · github.com/chenxingqiang/jax-sklearn

USER CODE

import xlearn as sklearn
public API

LinearRegression / KMeans / PCA
xlearn.linear_model · cluster · decomposition

set_config / config_context
xlearn/_jax/_config.py

PACKAGE INIT xlearn/__init__.py

__getattr__(name)
lazy submodule import

inject

_JAX_ENABLED
import xlearn._jax

_auto_jax_accelerate_module
replace estimator classes

AcceleratorRegistry
xlearn/_jax/_accelerator.py

PROXY xlearn/_jax/_proxy.py

create_intelligent_proxy
wrap estimator type

EstimatorProxy.__init__
_create_implementation()

JAX

JAX path
create_accelerated_estimator

fallback

sklearn fallback
original_class(*args)

JAX KERNELS xlearn/_jax/

_universal_jax.py
generic mixins JIT/vmap

_accelerator.py
dispatch + registry

_data_conversion.py
NumPy ↔ JAX

_gp.py
Gaussian process

_mlp.py
neural_network

_svm.py
SVM

_tree.py
trees

CONFIG / HEURISTICS xlearn/_jax/_config.py

enable_jax
on/off

jax_platform
cpu | gpu | tpu | metal

LinearRegression
min_complexity 1e8

KMeans
min_complexity 1e6

PCA
min_complexity 1e7

HARDWARE (JAX backends)

CPU jaxlib
default

CUDA jax[gpu]
NVIDIA

TPU jax[tpu]
Google Cloud

Metal jax-metal
Apple experimental

Injection is lazy: xlearn.__getattr__ → proxy class in module → fit() chooses JAX or sklearn

SECRET-LEARN — SYSTEM ARCHITECTURE

Privacy-preserving ML · source: docs/secret_learn_architecture.drawio + src/secretlearn/ · github.com/chenxingqiang/Secret-Learn

APPLICATION & USE CASES

- **Healthcare** — hospital FL
- **Finance** — cross-bank fraud
- **IoT / Edge** — distributed sensors
- **Research** — multi-institution
- **Government** — census / tax

SKLEARN-COMPATIBLE API 191 algorithms

- **Linear 39** — Ridge Lasso SGD
- **Ensemble 18** — RF AdaBoost
- **Clustering 14** — KMeans DBSCAN
- **Decomposition 14** — PCA NMF ICA
- **SVM 7** — SVC SVR NuSVC
- **NN 4** — MLP BernoulliRBM
- **+95** — neighbors trees NB …

PRIVACY MODES src/secretlearn/{federated_learning,secret_sharing,split_learning}/

FEDERATED LEARNING
federated_learning/
FLLinearRegression
local PYU · HEU aggregate
191 algos · 3–5×

SECRET SHARING
secret_sharing/
SSPCA
SPU MPC ABY3/CHEETAH
191 algos · max privacy

SPLIT LEARNING
split_learning/
SLMLPClassifier
model split · HEU acts
191 algos · vertical FL

INTELLIGENT SYSTEM + JAX

- **algorithm_classifier.py** — src/secretlearn/algorithm_classifier.py
- **JIT / XLA** — xlearn backend
- **jax.vmap** — batch + autodiff
- **smart fallback** — original sklearn

SECRETFLOW DEVICES

- **PYU** — plaintext party compute
- **HEU** — homomorphic aggregate
- **SPU** — MPC ABY3 / CHEETAH
- **TEE** — trusted execution

INFRASTRUCTURE & HARDWARE

- **CPU 1.5–2.5×** — local JAX
- **GPU 5–8×** — CUDA
- **TPU 9–15×** — Google
- **M1/M2 2–4×** — Metal beta

Same sklearn call surface; mode directory picks FL / SS / SL · 191 × 3 = 573 implementations

YOUTUBE-DNN-RECSYS — SYSTEM ARCHITECTURE

Covington two-tower recall · source: docs/architecture.drawio · github.com/chenxingqiang/YouTube-DNN-RecSys

DATA PROCESSING

data2tfrecords.py
src/python/data/data2tfrecords.py
random + TFRecords train/eval

read_tfrecords.py
src/python/data/read_tfrecords.py

MakeDataOne.scala
src/scala/data/MakeDataOne.scala
Spark distributed generate

MakeDataTwo.scala
src/scala/data/MakeDataTwo.scala
HDFS TFRecords

STORAGE

TFRecords

data/tfrecords/
train + eval TFRecords

data/checkpoints/
TF ckpt + SavedModel

MODEL src/python/models/dnn.py (TensorFlow Estimator)

Input
visit_items_index (5)
continuous_features (16)

Embedding
item_table-54
average pooling on history

MLP tower
dense layers → user vector u

Softmax
500-way next-item
cross entropy · Top-K

SavedModel

PREDICTION

load_dnn_model.py
src/python/models/load_dnn_model.py
SavedModel online / batch

PredictUserVector.scala
src/scala/prediction/PredictUserVector.scala

ItemEmbeddingPredictor.scala
src/scala/prediction/ItemEmbeddingPredictor.scala

ItemEmbedding.scala
src/scala/models/ItemEmbedding.scala

UTILITIES & CONFIG

tensor_board.py
src/python/utils/tensor_board.py

feature_column.py
src/python/reference/feature_column.py

self_defined_network_layer.py
src/python/reference/self_defined_network_layer.p

FeatureBuilder.scala
src/scala/models/FeatureBuilder.scala

BaseSparkLocal/Online
src/scala/core/*.scala

vars.prod/sit.properties
src/scala/config/

Python/TF path and Scala/Spark path share TFRecords + the same two-tower (history pool → user vec · item table)

RESEARCH CLI — SYSTEM ARCHITECTURE

TypeScript monorepo · packages/cli + packages/core · github.com/iechor-research/research-cli

packages/cli

- **research.tsx / TUI** — packages/cli/src
- **commands/** — mcp.ts skills.tsx hooks.tsx
- **config/config.ts** — packages/cli/src/config/config.ts
- **acp/** — acpSession.ts acpCommandHandler.ts

packages/core orchestration

- **config.ts** — packages/core/src/config/config.ts
- **research-config-manager.ts** — packages/core/src/config/
- **modelRouterService.ts** — packages/core/src/routing/
- **routingStrategy.ts** — default/classifier/composite
- **memory.ts / storage.ts** — session + compress

route

TOOLS + MCP

- **workspace tools** — fs / shell packages/core/src/tools
- **MCP** — packages/cli/src/commands/mcp.ts
- **sandbox** — config/sandbox-integration
- **packages/sdk** — programmatic embed
- **packages/a2a-server** — agent protocol
- **vscode-ide-companion** — IDE bridge

ACADEMIC MODULES packages/core/src/tools/research/

- **writing** — outline / LaTeX
- **bibliography** — arXiv / PubMed / BibTeX
- **analysis** — stats / citation net
- **investigation** — experiment codegen
- **submission** — journal matcher

PROVIDERS model-provider-config.ts + /model config

- **Gemini / Vertex**
- **OpenAI**
- **Anthropic**
- **Baidu ERNIE**
- **DeepSeek**
- **Qwen / Groq / Kimi**

CLI TUI → core config/router → provider + tools/MCP/research modules → streamed result

QUESTIONS-GEN — SYSTEM ARCHITECTURE

Qwen3-14B contest problems · src/*.py + questions_gen/ · github.com/chenxingqiang/GenQuestion

DATA

QuestionDataPreparer.py
src/QuestionDataPreparer.py

data_preparer.py
questions_gen/data/data_preparer.py

real_math_data_processor.py
src/real_math_data_processor.py

mixture
historical 50% · variants 30% · novel 20%

THREE-STAGE TRAINER

QuestionsGenTrainer.py
src/QuestionsGenTrainer.py
questions_gen/core/trainer.py
Stage1 SFT Qwen3-14B

reward

RewardCalculator.py
src/RewardCalculator.py
0.4 diff 0.3 nov 0.2 rigor 0.1 div

reward

NoveltyConstraint.py
src/NoveltyConstraint.py
GRPO 8-problem groups

DeepSeekTeacher.py
src/DeepSeekTeacher.py
Stage3 distill R1

config.py
src/config.py
questions_gen/core/config.py

VALIDATION questions_gen/validation/

model_validator.py
single-model n tests

batch_validator.py
algebra/calculus/geometry/NT

quality_evaluator.py
content clarity difficulty originality

PACKAGE / CLI / DEPLOY

main_cli.py
questions_gen/cli/main_cli.py
validate batch quality

ollama_manager.py
questions_gen/utils/ollama_manager.py

hf_utils.py
questions_gen/utils/hf_utils.py

questions_gen_training.py
scripts/questions_gen_training.py

ARTIFACTS Hugging Face xingqiang/*

stage1-fp-merged
SFT

stage2-merged-16bit
GRPO

final-merged-16bit
distill quality 0.847

Ollama questions-gen-final
local generate

Stage1 SFT → Stage2 GRPO (RewardCalculator + NoveltyConstraint) → Stage3 DeepSeekTeacher → HF/Ollama