# CHEN XINGQIANG

杭州，中国

+86 150-0133-4125 ◇ joy6677@outlook.com ◇ github.com/chenxingqiang

## 求职意向

寻求**全职**职位：**AI 加速器编译器 / 系统软件 · 大语言模型推理系统 · 软硬件协同设计**。

## 交叉学科背景

理论物理与生物物理训练，贯通计算化学、分子动力学与计算机科学。竞赛：**全国大学生数学建模竞赛国家一等奖**（2012）、**北美大学生数学建模竞赛（MCM）一等奖**（2013）；**CCF 开源 GPU 创新生态赛 GPU 算子优化挑战赛二等奖**（2025）。

## 教育背景

**生物物理学与凝聚态物理博士研究生**（结业，学位答辩中） 2014 年 9 月 - 2018 年 7 月
厦门大学，物理与机电工程学院；导师方向：蛋白质动力学与 QM/MM 仿真

**理论物理学学士** 2010 年 9 月 - 2014 年 7 月
厦门大学，物理与机电工程学院

## 技能与项目

**编程语言**：C++、Python（主要）；CUDA、Java、Scala、Go。

**编译器 / 工具链**：MLIR、LLVM 后端与 ISA 适配、TVM、图划分与算子融合、成本建模、CodeGen、自动调优。

**芯片软件 / 验证**：Palladium Emulation、GDB 与仿真模型联调、固件与权重映射生成、算子级指标（Cycles/MACs）分析。

**推理系统**：Transformers、KV-Cache、量化、批处理与调度、Triton 内核、FlashAttention、CUPTI/Perfetto 性能剖析。

**平台**：PyTorch、TensorFlow、ONNX、Kubernetes；Spark、Flink、Hadoop。

**开源与发布**（默认位于 `github.com/chenxingqiang`，均可公开验证）：

- **TraceSmith**：跨平台 GPU Profiling & Replay 系统，覆盖 CUDA/ROCm/Metal/MACA/Ascend；C++ 核心 + Python 绑定，已发布至 PyPI。`TraceSmith`
- **YiRage 持久化内核（YPK）**：LLM 超级内核编译器与运行时，多后端（CUDA/CPU/MPS/Ascend/Triton）。`YiRage`
- **JAX-sklearn**：scikit-learn 兼容接口 + JAX 加速，13,058 项测试通过，PyPI 发布。`jax-sklearn`
- **Secret-Learn**：隐私保护机器学习库，覆盖联邦学习／秘密分享／分割学习，PyPI 发布。`Secret-Learn`
- **YouTube-DNN-RecSys**：YouTube 风格召回与排序的 TensorFlow + Spark 实现（60 stars）。`YouTube-DNN-RecSys`
- **Research CLI**：面向科研工作流的命令行 AI 工具，多模型供应商与 MCP 集成。`iechor-research/research-cli`
- **Questions-Gen**：数学竞赛题目生成（Qwen3-14B、GRPO、蒸馏），含 CLI 与 Hugging Face 权重。`GenQuestion`

## 工作经历

### 编译器 & 工具链专家，知存算力（Witmem） 杭州，中国

**编译器 / *Palladium* 验证** *2025* 年 *12* 月 *10* 日 - 至今

- 负责存算芯片产品线编译器与 Palladium 仿真验证，覆盖模型编译、指令生成、芯片执行及 Emulation 缺陷定位。
- 完成 Palladium 软件 Bring-up：Compiler 输出在仿真器上运行，结合 GDB 在仿真模型、芯片与系统软件层做联合调试。
- 实现 **CIM-MLIR** 异构编译器：PyTorch/TensorFlow/ONNX 经 TOSA/StableHLO 映射至 CPU、GPU 与 CIM，含前端、图划分、硬件后端与运行时。
- 实现代价驱动图划分与 CIMHigh/Mid/Low 三级 IR；用 OR-Tools 分配 Die/L2/L0 资源，生成可烧录 **config.bin**、权重 **map.bin**，以及 GPU PTX 与 LLVM 主机代码。

- 实现跨设备运行时：分设备执行器、统一内存、计算与传输重叠及三级缓冲；提供 C++/Python 接口及延迟、利用率、传输开销统计。
- 实现 **GRC-PIM**：PIM 上基于 drift gating 与 GEMV 复用的残差校准及软判决纠错，投稿 *npj Unconventional Computing*（详见发表论文）。

### 高级 AI 编译器工程师，亿铸智能
杭州，中国

**研发部门** *2022* 年 *9* 月 - *2025* 年 *12* 月

- 主导 **YiRage 持久化内核（YPK）**：将端到端 LLM 解码编译为单个超级内核；在 Llama2-7B、单卡 A100 上相对 PyTorch eager 基线取得 **1.2×–6.7×** 端到端延迟收益（随 batch 与序列长度变化）。
- 实现融合算子（RMSNorm+Linear、GQA 等）与持久化执行模型，显著减少内核启动与中间张量往返；batch=1 decode 路径延迟降幅最大。
- 构建调度层并集成 Triton 与 FlashInfer 内核，支持多卡扩展（最高验证 8 卡）与 NVSHMEM 张量。
- 开发图编译与自动调优：内核参数搜索、KV-cache 友好内存布局，降低访存开销。
- 申请 **2 项**发明专利；相关能力交付 **2 个**数据中心客户 PoC。
- 负责公司 SoC 的 LLVM 后端 Target 与复杂指令集适配，推进编译器后端规范化与软件生态建设。
- 搭建模型转换与算子级评估流程：将 TVM、ONNX、MLCommons、TensorFlow/PyTorch 集成入 YZlite，统计 Cycles/MACs 等指标并输出多芯片 benchmark。开源工具包 `ReRAM-Labs/yzlite`。

### 隐私保护算法工程师，蓝象智联
杭州，中国

***IT Group*** *2022* 年 *1* 月 - *2022* 年 *9* 月

- 构建基于同态加密的联邦学习平台，支撑多家金融机构的跨域建模；在保持隐私约束下相对本地基线提升模型效果，并缩短训练迭代周期。
- 设计多方安全计算协议，用于银行风控模型的联合训练与推理，兼顾协议安全性与通信开销。
- 开源 **Secret-Learn**：sklearn 兼容 API × 联邦学习／秘密分享／分割学习三种模式，JAX 加速，并与 SecretFlow 集成，PyPI 发布。`Secret-Learn`
- 申请 **3 项**发明专利（均已公开，可检索）：
- 基于秘密分享的纵向联邦线性支持向量分类方法 `CN114925786A`；随机森林训练方法及装置 `CN114997345A`；用于联邦学习的数据处理方法及装置 `CN115130681A`。

### T7 算法工程专家，百图生科
北京，中国

**算法工程组** *2021* 年 *9* 月 - *2021* 年 *12* 月

- 构建生物信息学工具链与数据平台，统一大规模生物数据的管理、检索与分析流程，支撑序列分析、结构预测与功能注释。
- 搭建蛋白质结构预测模型评估流程（含 AlphaFold 系列），为药物设计提供结构输入。
- 获 **2 项**软件著作权：生信工具自动化平台（2021SR2004464）、生物医药信息平台（2021SR1862397）；开源 AlphaFold2 代码解析与学习资源（26 stars）`alphafold2-codecs`。

### 高级算法工程师，Yalla 集团 (纽交所: YALA)
杭州，中国

**数据中心工程组** *2020* 年 *9* 月 - *2021* 年 *9* 月

- 重构 Yalla 聊天室推荐系统，引入多目标排序；A/B 实验中人均日活跃时长与 7 日留存均取得显著正向（留存 **42%** → **61%**）。
- 构建 Ludo 风控系统，结合实时行为特征与机器学习模型识别异常账号，显著降低恶意退款比例。
- 开发卡牌类游戏 AI（深度强化学习），用于人机对局与匹配填充，提升低峰时段对局体验与留存。

### 高级算法工程师，格家网络科技
杭州，中国

**搜索推荐工程组** *2019* 年 *3* 月 - *2020* 年 *9* 月

- 设计多场景推荐架构，融合协同过滤、深度排序模型与商品知识图谱；线上实验 CTR 与 CVR 均取得两位数相对提升。
- 优化实时推荐链路：特征缓存与召回裁剪，P99 响应控制在 **50ms** 内，支撑大促期间峰值流量。

### 机器学习工程师，便利蜂科技
北京，中国

**数据工程组** *2017* 年 *3* 月 - *2019* 年 *3* 月

- 构建门店销量预测系统（覆盖 **50+** 门店），引入格点气象与时空特征，降低缺货与滞销率、提升库存周转。
- 开发用户与商品关联分析：在千万级行为数据上打通客户身份与购买记录，支撑个性化推荐。
- 设计商品视觉识别模型（**500+** SKU），用于快速结算场景，缩短收银与排队时间。

## 研究与实习

### 蛋白质分子动力学仿真与 QM/MM 模型
厦门大学，中国
**(国家自然科学基金项目)** *2014* 年 *9* 月 - *2017* 年 *3* 月

- 以 QM/MM 方法开展蛋白质动力学仿真与构象分析，成果发表于 Acta Cryst. D、PLoS ONE、Phys. Rev. E 等（见发表论文）。

### 液体活检 ct-DNA 试剂盒开发与 DNA 甲基化数据分析
乐普医疗，中国
**(研发工程师实习)** *2016* 年 *3* 月 - *2017* 年 *3* 月

- 在 TCGA/GEO 公开基因芯片数据上分析约 10,000 例样本，定位 Septin9 基因甲基化位点（结肠癌早期标志物），支撑临床诊断试剂盒的标志物筛选。

## 获奖与评审

- **国家一等奖**，全国大学生数学建模竞赛（CUMCM），2012 年。
- **一等奖**（Meritorious Winner），北美大学生数学建模竞赛（MCM/COMAP），2013 年。
- 全球**第 6 名**，国际太阳能十项全能竞赛（Solar Decathlon），2013 年。
- 第 **57** 名与第 **32** 名（共 1739 队），IEEE ICDM 全球气象 AI 挑战赛，2018 年。
- **二等奖**，第八届 CCF 开源创新大赛・开源 GPU 创新生态赛常规赛 S1 ・GPU 算子优化挑战赛（CCF/ODTC），2025 年。CCF 公示
- 评委，应用算法最佳实践初审，2021 年。

## 发表论文

- Chen X. GRC-PIM: A Drift-Gated, GEMV-Reusing Residual Calibrator for Soft-Decision Error Correction in Processing-in-Memory. *npj Unconventional Computing*（投稿中）。
- Cai Y, Su M, Ahmad A, Hu X, Sang J, Kong L, Chen X, Wang C, Shuai J, Han A. Conformational dynamics of the essential sensor histidine kinase WalK. *Acta Crystallographica Section D: Structural Biology*. 2017 Oct 1;73(10):793-803.
- Xia H, Chen X, Chen X, Cheng J, Liu Y, Chen X, Zhang Q, Zou G. Chiral discrimination of amino acid enantiomers based on different interactions with Cu2+. *Sensors and Actuators B: Chemical*. 2018 Jan 1;254:44-51.
- Ahmad A, Cai Y, Chen X, Shuai J, Han A. Conformational dynamics of response regulator RegX3 from Mycobacterium tuberculosis. *PloS one*. 2015 Jul 22;10(7):e0133389.
- Chen Y, Qi H, Li X, Cai M, Chen X, Liu W, Shuai J. Suppressing effect of C a 2+ blips on puff amplitudes by inhibiting channels to prevent recovery. *Physical Review E*. 2016 Aug 15;94(2):022411.

# 开源项目架构附录

陈星强 · github.com/chenxingqiang · 每页包含项目介绍与模块级系统架构




## 阅读约定

自上而下阅读。虚线框是架构分区，内层实线框是子系统，小盒子是具体模块。

蓝色实线是主数据流，紫色虚线是回退或反馈，不把源码目录本身当成架构层。

# TraceSmith — 系统架构 · GPU Trace 端到端数据流

Application → _tracesmith.so → Capture / State / Format → Replay → GPU backends → trace outputs

主数据流　虚线框 = 架构分区
回退 / 反馈　盒内 = 模块 + 职责

**项目介绍**

TraceSmith 是面向 AI 编译器、深度学习框架与 GPU 驱动工程师的跨平台性能分析和确定性回放系统。

C++17 核心以低开销采集执行事件，写入紧凑 SBT 轨迹，并导出时间线用于分析、调试与问题复现。

## APPLICATION · 用户入口

- **C++ Application** — 嵌入业务进程
- **Python Application** — 嵌入业务进程
- **C++ CLI** — tracesmith; profile · record · view
- **Python CLI** — tracesmith-cli; export · analyze · replay
- **External UI** — Perfetto UI; Chrome tracing

## BINDINGS · Python / C++ 边界

- **_tracesmith.so** — python/src/bindings.cpp; pybind11 native extension

## CORE LIBRARY · C++17

### Cluster Module

- **GPUTopology** — NVLink · PCIe · NVML
- **MultiGPUProfiler** — 跨设备采集
- **TimeSync** — NTP / PTP / CUDA
- **NCCLTracker** — 集合通信
- **ClockCorrelator** — 时钟对齐
- **CommAnalysis** — 通信矩阵

### Capture Module

- **CUPTIProfiler** — NVIDIA CUDA
- **MCPTIProfiler** — MetaX MACA
- **MetalProfiler** — Apple Metal
- **MemoryProfiler** — GPU 内存
- **AscendProfiler** — Huawei CANN
- **createProfiler()** — nsys · mcTracer; xctrace · msprof

### State Module

- **GPUStateMachine** — 状态分析
- **InstructionStream** — 依赖图
- **TimelineBuilder** — 事件排序
- **TimelineViewer** — ASCII 渲染
- **PerfettoExporter** — JSON
- **PerfettoProtoExporter** — Protobuf

### Replay Module

- **ReplayEngine** — 回放编排
- **StreamScheduler** — 操作顺序
- **OperationExecutor** — 执行回放
- **DeterminismChecker** — 结果比对
- **FrameCapture** — RenderDoc-style

### Common Module

- **Types** — TraceEvent · EventType; KernelParams
- **RingBuffer** — lock-free SPSC
- **StackCapture** — libunwind
- **XRayImporter** — LLVM XRay
- **Timestamps** — ns precision
- **TraceMetadata** — DeviceInfo

### Format Module

- **SBTWriter** — 二进制写入
- **SBTReader** — 二进制读取
- **.sbt** — header + events; counters

### Configuration

- **ProfilerConfig** — 缓冲与溢出
- **ReplayConfig** — 模式与速度
- **StackCaptureConfig** — 调用栈策略
- **NCCLTrackerConfig** — 集合通信策略

### GDB Module

- **RSPHandler** — GDB protocol
- **ProcessController** — ptrace / Mach
- **GPUDebugEngine** — 断点与回放
- **tracesmith-gdbserver** — v0.10.0

回放

## GPU BACKENDS · 系统接口

- **NVIDIA CUDA** — CUPTI SDK
- **Apple Metal** — Metal API
- **MetaX MACA** — MCPTI SDK
- **NCCL** — 分布式
- **Nsight Systems** — nsys
- **mcTracer** — MetaX
- **xctrace** — Apple
- **libunwind** — 主机调用栈
- **Perfetto SDK** — 轨迹导出

## OUTPUTS · Trace 产物

- **trace.sbt** — 二进制格式
- **trace.json** — Perfetto JSON
- **trace.perfetto** — Protobuf
- **graph.dot** — Graphviz
- **ASCII Timeline** — 终端
- **Comm Matrix** — 热力图 JSON

主链：GPU event → RingBuffer → SBT/state → replay 或 Perfetto。Cluster、配置与 GDB 是并列能力。

# YiRage (YPK) — 系统架构 · RuntimeFusion 数据流

Engine owns schedule + KV; RF owns fusion identity; BackendRegistry searches and executes the same backend

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

**项目介绍**

YiRage 是面向大模型推理的多后端算子编译与运行时系统，核心能力是计算图超优化和 RuntimeFusion。

系统离线搜索并验证后端特定融合计划，再将 FusionCapsule 注入 vLLM 或 SGLang 的逐步解码流程。

## INFERENCE ENGINE · 调度与 KV 所有者

- **vLLM** — continuous batch · PagedAttention
- **SGLang** — RadixAttention · extend meta
- **Decode Metadata** — block_table · seq_lens · radix hit · SM budget · batch

## RuntimeFusion · RF.step(inputs, meta)

- **RF.step** — select 0..N capsules per decode step
- **FusionCapsule** — MLP gate_up + down · yirage.core
- **FusionCapsule** — segment pipeline · gate_up → down
- **Native Fallback** — skip → engine native ops

## SEARCH & PLAN · 离线搜索与预热

- **superoptimize** — KN / TB graph search
- **FusionPlan** — μGraph · profile + fingerprint
- **MuGraph cache** — shape bucket restore
- **Ray Coordinator** — 可选分布式搜索
- **Serving Tiers** — seed_verify · full_tb · full_tb_ray

## PYTHON API 与 BACKEND MANAGER

- **KNGraph / TBGraph** — transpiler → kernels
- **BackendRegistry** — search + execute · same backend
- **yirage.core** — Cython runtime
- **yirage.serving** — RF · Capsule · cert
- **MACA Config** — warp = 64 · mxcc
- **CPU MLIR JIT** — 可选

## BACKEND IMPLEMENTATIONS · 后端实现

- **CUDA** — nvcc · warp 32
- **MACA** — mxcc · warp 64
- **CPU** — OpenMP · MKL
- **MPS** — Apple GPU
- **Ascend** — CANN
- **ROCm** — AMD GPU
- **Triton** — DSL kernels
- **+ extra** — TPU · XPU · FPGA · MLIR

## HARDWARE TARGETS · 硬件目标

- **NVIDIA GPU**
- **MetaX C500/C550**
- **x86 / ARM CPU**
- **Apple Silicon**
- **Huawei Ascend**
- **AWS Neuron** — Intel XPU

回退

主链：decode metadata → RF.step → FusionCapsule → BackendRegistry → 同一后端与硬件。

# JAX-sklearn (xlearn) — 五层架构 · 透明加速数据流

xlearn/__init__.py injects proxies; xlearn/_jax dispatches to JAX or the original sklearn estimator

主数据流　　虚线框 = 架构分区
回退 / 反馈　　盒内 = 模块 + 职责

**项目介绍**

JAX-sklearn 在保持 scikit-learn 调用接口不变的前提下，透明地以 JAX 加速受支持的估计器。
运行时代理依据算法、数据规模与硬件平台选择 JAX 或原生 sklearn，并保持输入输出兼容。

## USER CODE · sklearn 兼容接口

- **import xlearn as sklearn** — 100% call surface
- **Estimators** — linear_model · cluster · decomposition · preprocessing
- **Calls** — fit · predict · transform

## COMPATIBILITY · xlearn/__init__.py

- **__getattr__** — 惰性导入子模块
- **_auto_jax_accelerate_module** — 替换估计器类
- **AcceleratorRegistry** — _accelerator.py
- **create_intelligent_proxy** — _proxy.py
- **monkey_patch_estimator** — 安装代理类

## JAX ACCELERATION · xlearn/_jax

- **EstimatorProxy** — fit-time dispatch
- **create_accelerated_estimator** — _accelerator.py
- **_universal_jax.py** — JIT · vmap
- **original_class** — sklearn 回退
- **_gp.py** — Gaussian process
- **_mlp.py** — neural net
- **_svm.py** — SVM kernels
- **_tree.py** — tree models

回退

## DATA MANAGEMENT · 数组与策略

- **_data_conversion.py** — NumPy ↔ JAX · dtype · shape
- **_config.py** — enable_jax · jax_platform
- **jax_auto_threshold** — complexity >= 1e8
- **detect_hardware** — install command · platform probe

## HARDWARE · JAX 后端

- **CPU** — jax-cpu · jaxlib
- **CUDA GPU** — jax-gpu · jax-cuda11
- **TPU** — jax-tpu
- **Apple Metal** — jax-metal · float32 · experimental

主链：sklearn 调用 → 注入代理 → JAX 估计器。小数据、缺算子或执行失败时回到 original_class。

# Secret-Learn — 六层架构 · 隐私计算数据流

secretlearn API → FL / SS / SL placement → JAX acceleration → SecretFlow devices

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

**项目介绍**

Secret-Learn 以 sklearn 兼容接口提供联邦学习、秘密分享和拆分学习三种隐私机器学习模式。

系统结合 JAX 加速与 SecretFlow 安全设备，使工作流能够明确控制明文、秘密份额和中间激活的驻留位置。

## APPLICATION · 多方使用场景

- **Healthcare** — 跨院协作 · 患者隐私
- **Finance** — 跨行分析 · 欺诈检测
- **IoT / Edge** — 边缘智能 · 分布式学习
- **Research** — 基因组 · 多机构
- **Government** — 普查分析 · 跨部门数据

## SKLEARN API · 191 个算法

- **Linear Models** — 39 — Ridge · Lasso · SGD
- **Ensemble** — 18 — RF · XGBoost
- **Clustering** — 14 — KMeans · DBSCAN
- **Decomposition** — 14 — PCA · NMF · ICA
- **SVM** — 7 — SVC · SVR
- **Neural Networks** — 4 — MLP · BernoulliRBM
- **+ 95 More** — Neighbors · Trees · Naive Bayes

## PRIVACY MODES · 执行位置

### FEDERATED LEARNING · 联邦学习

- **Local PYU** — 数据留在本地
- **HEU Aggregate** — 安全聚合
- **FLLinearRegression** — federated_learning/
- **Horizontal FL** — 3–5×

### SECRET SHARING · 秘密分享

- **SPU MPC** — 密文计算
- **ABY3 / CHEETAH** — MPC 协议
- **SSPCA** — secret_sharing/
- **Maximum Privacy** — 1–2×

### SPLIT LEARNING · 拆分学习

- **Model Split** — 跨参与方切分
- **HEU Activations** — 保护中间激活
- **SLMLPClassifier** — split_learning/
- **Vertical FL** — 2–4×

## JAX ACCELERATION · xlearn 桥接

- **JIT / XLA** — 跟踪执行
- **jax.vmap** — 批处理与自动微分
- **xlearn Backend** — JAX-sklearn 桥
- **Smart Fallback** — 回退原生 sklearn
- **CPU** — 1.5–2.5×
- **GPU** — 5–8×
- **TPU** — 9–15×
- **M1 / M2** — 2–4×

## SECURE DEVICES · SecretFlow 设备

### SPU

- **MPC** — ABY3 · CHEETAH
- **Ciphertext** — 不暴露明文

### HEU

- **Schemes** — Paillier · CKKS
- **Aggregation** — 梯度保护

### TEE

- **Enclaves** — Intel SGX · AMD SEV
- **Occlum** — 证明

### PYU

- **Party Local** — 数据归属
- **JAX Local** — 本地明文计算

## INFRASTRUCTURE · 运行时基础设施

- **SecretFlow** — Ray distributed · gRPC · DP-SGD
- **JAX / XLA** — CUDA / cuDNN · TPU runtime
- **sklearn** — NumPy · SciPy

主链：同一次 sklearn 调用选择 FL、SS 或 SL，再落到 PYU、HEU、SPU 或 TEE。

# YouTube-DNN-RecSys — 系统架构 · 召回数据流

Python / Spark samples → TFRecords → dnn.py user tower → Spark or Python prediction

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

**项目介绍**

YouTube-DNN-RecSys 使用 TensorFlow 与 Spark 实现 YouTube 推荐系统中的候选召回阶段。

系统将用户行为历史转换为 TFRecords，训练用户与物品向量，并为在线服务生成 Top-K 召回候选。

## DATA PROCESSING · 数据处理层

### Python 数据处理

- **data2tfrecords.py**
  生成训练数据
- **TFRecords**
  训练与评估集
- **read_tfrecords.py**
  数据集读取

### Scala + Spark 数据处理

- **MakeDataOne.scala**
  分布式生成
- **MakeDataTwo.scala**
  TFRecords output
- **HDFS**
  数据集存储

## STORAGE · 存储层

- **data/tfrecords/**
  train/train.tfrecords
  evaluation/evaluation.tfrecords
- **data/checkpoints/**
  ckpt/checkpoint
  ckpt/eval · modelpath/

## MODEL TRAINING · dnn.py

- **Input**
  visit_items_index × 5
  continuous_features × 16
- **Item Embedding**
  500 items × 16
- **Average Pooling**
  历史向量
- **DNN Tower**
  Dense 64 + ReLU
  Dropout · Dense 32 + ReLU
  user vector 16
- **Softmax Output**
  500 classes
  cross entropy · Top-K

评估

## PREDICTION · 预测服务层

- **PredictUserVector.scala**
  SavedModel
  embedding_average → user_vector
- **ItemEmbeddingPredictor.scala**
  item embedding table
  FeatureBuilder
- **load_dnn_model.py**
  SavedModel load
  在线与批量推理

## UTILITIES · 工具与辅助层

- **tensor_board.py**
  TensorBoard
- **feature_column.py**
  特征列
- **self_defined_network_layer.py**
  自定义网络层
- **Spark Base**
  BaseSparkLocal.scala
  BaseSparkOnline.scala
- **Configuration**
  vars.prod.properties
  vars.sit.properties

主链：行为历史 → TFRecords → embedding average pool → user vector → item table → Top-K。

# Research CLI — 系统架构 · Agent 请求数据流

packages/cli → packages/core routing → tools / MCP / research modules → model providers

主数据流　虚线框 = 架构分区
回退 / 反馈　盒内 = 模块 + 职责

**项目介绍**

Research CLI 是终端优先的 AI Agent 工作流，将交互会话连接到模型、工作区工具和 MCP 服务。

核心路由负责上下文与模型供应商选择，研究模块覆盖论文写作、文献管理、数据分析和投稿准备。

## CLI FRONTEND · packages/cli

- **research.tsx** — 交互终端
- **commands/** — mcp.ts · skills.tsx · hooks.tsx
- **ui/commands/research** — arxivCommand · paper · investigate · submit
- **acpSession.ts** — ACP session · stdio transport

## CORE ORCHESTRATION · packages/core

### 会话

- **researchChat.ts** — researchRequest.ts
- **research-config-manager.ts** — 学术配置
- **config / memory** — 上下文

### 路由

- **modelRouterService** — routing/modelRouterService.ts
- **defaultStrategy** — routingStrategy.ts
- **classifierStrategy** — gemma · numerical
- **compositeStrategy** — approval · fallback · override

## TOOLS 与 RESEARCH MODULES

### Workspace

- **edit.ts · grep.ts** — filesystem changes
- **shell / ls** — 本地执行

### MCP

- **mcp-client.ts** — 服务会话
- **mcp-client-manager.ts** — 资源路由

### analysis/

- **bibliography-manager** — citations
- **experiment-code-generator** — Python · R · Julia
- **research-data-analyzer** — 统计与机器学习

### bibliography/

- **arxiv-mcp-client** — arXiv search
- **google-scholar-client** — scholar search
- **literature-investigator** — keyword-generator · reference-classifier

### submission/

- **latex-manager** — project compile
- **journal-matcher** — 期刊匹配
- **arxiv-latex-extractor** — 模板提取

回路

## MODEL PROVIDERS · 模型供应商

- **Gemini / Vertex**
- **OpenAI**
- **Anthropic**
- **Baidu ERNIE**
- **DeepSeek**
- **Qwen**
- **Groq / Mistral** — Cohere · Moonshot

## EMBEDDED RUNTIMES · 嵌入运行时

- **packages/sdk** — 库嵌入
- **packages/a2a-server** — agent executor · HTTP task API
- **vscode-ide-companion** — IDE companion
- **packages/devtools** — 开发工具

主链：prompt → research.tsx → modelRouterService → provider；工具和研究模块返回观察结果。

# Questions-Gen — 系统架构 · 三阶段训练数据流

Question data → Qwen3-14B SFT → GRPO reward → DeepSeek-R1 distillation → validation → publish

主数据流　　虚线框 = 架构分区
回退 / 反馈　　盒内 = 模块 + 职责

**项目介绍**

Questions-Gen 是基于 Qwen3-14B 的数学竞赛题生成与评估系统，采用分阶段训练策略。

训练链路结合监督微调、GRPO 奖励优化、DeepSeek-R1 蒸馏、质量验证以及 Hugging Face 和 Ollama 部署。

## TRAINING DATA · 训练数据混合

- **Historical** — 50% — QuestionDataPreparer.py
- **Conditional Variants** — 30% — data_preparer.py
- **Innovative Types** — 20% — real_math_data_processor.py

## Stage 1 · SFT · 监督微调

- **Qwen3-14B** — 基座模型
- **QuestionsGenTrainer.py** — src/ + questions_gen/core/trainer.py
- **stage1-fp-merged** — Hugging Face

## Stage 2 · GRPO · 奖励优化

### RewardCalculator.py

- **Difficulty** — 0.4 difficulty
- **Novelty** — 0.3
- **Rigor** — 0.2
- **Diversity** — 0.1

### 优化

- **GRPO Groups** — 8 problems/group
- **NoveltyConstraint.py** — 重复约束
- **stage2-merged-16bit** — variation generation

质量

## Stage 3 · Distill · 知识蒸馏

- **DeepSeekTeacher.py** — DeepSeek-R1
- **Teacher Signals** — 难度与严谨性 / 创新与教学价值
- **final-merged-16bit** — Hugging Face

## VALIDATION · questions_gen/validation

- **model_validator.py** — 单模型
- **batch_validator.py** — algebra · calculus / geometry · number theory
- **quality_evaluator.py** — clarity · difficulty / originality

## DEPLOYMENT · 发布与接口

- **main_cli.py** — validate · batch · quality
- **hf_utils.py** — three published stages
- **ollama_manager.py** — 本地推理
- **examples/** — quick_demo.py / demo_model_validation.py

主链：混合题库 → SFT → GRPO reward 与 novelty → DeepSeek-R1 蒸馏 → 验证 → Hugging Face / Ollama。