CHEN XINGQIANG

杭州，中国
+86 150-0133-4125 ⋄ joy6677@outlook.com

求职意向

寻求**全职**职位：**大语言模型推理系统 AI Agent AI 编译器 基础模型应用方向 推荐系统**。

教育背景

生物物理学与凝聚态物理博士 2014 年 9 月 - 2018 年 7 月
厦门大学，物理与机电工程学院 GPA：3.5/4.0

理论物理学学士 2010 年 9 月 - 2014 年 7 月
厦门大学，物理与机电工程学院 GPA：3.0/4.0

技能与项目

编程语言：精通 Python、Java、Scala、Go。

MLOps 工具：熟练使用 Hadoop、Flink、Spark、Kubernetes、KubeFlow、TensorFlow、PyTorch 等。

大语言模型 推理系统：Transformers、KV-Cache、量化、批处理与调度、Triton 内核、CUDA、FlashAttention、图融合、GPU Profiling 与 Replay。

AI 编译器 内核：图编译、持久化超级内核、算子融合、成本建模；LLM 编译器与运行时 (YiRage YPK)；GPU 轨迹采集与回放 (TraceSmith)。

深度学习模型：精通 Transformers、RL、GNN、DNN、CNN 等。

跨学科专长：具有物理学、计算生物学、计算化学、分子动力学、量子力学仿真和计算机科学背景。

开源亮点：

- **TraceSmith** —面向 AI 编译器与深度学习框架的跨平台 GPU Profiling & Replay 系统(CUDA/ROCm/Metal/MACA/Ascend；无锁采集、确定性回放；PyPI 发布)。

  `https://github.com/chenxingqiang/TraceSmith`

- **Research CLI** —具有学术研究功能的命令行 AI 工作流工具；支持多模型提供商和 MCP 工具。

  `https://github.com/iechor-research/research-cli`

- **JAX-sklearn** —具有自动 JAX 加速功能的 scikit-learn 替代方案（*13,058* 项测试通过；*PyPI* 发布)。

  `https://github.com/chenxingqiang/jax-sklearn`

- **YouTube-DNN-RecSys** —YouTube 风格推荐模型的简洁 TensorFlow 与 Spark 实现（Python+Scala)。

  `https://github.com/chenxingqiang/YouTube-DNN-RecSys`

- **Questions-Gen** —数学竞赛题目生成器（Qwen3-14B、RL GRPO、KD；CLI 与 HF 模型)。

  `https://github.com/chenxingqiang/GenQuestion`

- **DeepMicroPath** —多模式研究 Agent，提供微生物学专业模式；以非侵入式包装器实现 auto/default/microbiology Prompt，支持 Docker/SLURM 部署。

  `https://github.com/chenxingqiang/DeepMicroPath`

- **Medical-NER-Qwen-4B-Thinking** —通过 LoRA 微调的 Qwen3-4B-Thinking 用于医疗实体与关系抽取（英语)。

  `https://huggingface.co/xingqiang/Medical-NER-Qwen-4B-Thinking`

- **QuestionsGen-Qwen3-14B-Final (FP)** —使用 Unsloth 训练的全精度合并最终模型；部署就绪的 HF 权重。

  `https://huggingface.co/xingqiang/QuestionsGen-Qwen3-14b-final-fp-merged`

- **YiRage 持久化内核 (YPK)** —LLM 超级内核编译器与运行时，实现 1.2×–6.7× 延迟缩减。

  `http://github.com/chenxingqiang/YiRage`

工作经历

高级 AI 编译器工程师，亿铸智能
杭州，中国
研发部门
2022 年 *9* 月 - 至今

- 主导开发 **YiRage 持久化内核 (YPK)**，将端到端 LLM 推理编译成单个超级内核，在 Llama2-7B 上实现 **1.2×–6.7× 延迟缩减**，GPU 利用率提升 **40%**，显存占用减少 **25%**。
- 设计并实现融合算子架构（RMSNorm + Linear 等），消除 **85%** 的内核启动开销，单次推理延迟从 **120ms 降至 18ms**（批大小 =1）。
- 构建自适应调度系统，整合 Triton 与 FlashInfer 内核，支持多 GPU 扩展至 **8 卡并行**，吞吐量达到 **15,000 tokens/秒**。
- 开发图编译优化器，实现自动内核参数调优和 KV-cache 内存布局优化，内存访问效率提升 **60%**，缓存命中率达到 **92%**。
- 技术成果转化：申请 **2 项**发明专利，产品已部署到 **2 个**数据中心客户。
- 在 ReRAM 芯片公司主要负责编译器后端适配与本公司软件生态构建，当前聚焦公司 SoC 的 LLVM 后端 Target 研发，推进代码规范化与复杂指令集架构开发。
- 承担 AI 模型（含 LLMs）的转换与细粒度分析，适配多种运行时格式，评估推理阶段算子指标（Cycles/MACs 等）与计算效率；集成 TVM、ONNX、MLCommons、TensorFlow/PyTorch 于 YZlite，对多种模型运行时进行算子级指标统计并输出各类芯片上的 benchmark。

隐私保护算法工程师，蓝象智联
杭州，中国
IT Group
2021 年 *9* 月 - *2022* 年 *9* 月

- 构建基于同态加密的联邦学习平台，支持 **20+** 金融机构数据协作，在保护隐私前提下模型精度提升 **15%**，训练时间缩短 **40%**。
- 设计多方安全计算协议，为 **8 家**银行提供风控模型联合训练服务，欺诈检测准确率达到 **96.7%**，误报率降低 **30%**。
- 开源贡献：开发 **Secret-Learn** 隐私保护机器学习库，实现 **573 个**算法（191 算法 × FL/SS/SL 三种隐私模式），100% sklearn API 兼容，集成 JAX 加速（**5×+** 性能提升）和 SecretFlow 隐私计算框架，支持联邦学习、秘密分享、分割学习等多种隐私保护场景（**PyPI 发布，150,000+ 行代码**）。
  `https://github.com/chenxingqiang/Secret-Learn`
- 技术创新产出：发表 **2 篇**隐私计算领域论文，申请 **3 项**核心算法专利，核心技术被 **5 个**商业产品采用，创造营收 **800 万**人民币。

高级算法工程师，Yalla 集团 (纽交所: YALA)
杭州，中国
数据中心工程组
2020 年 *9* 月 - *2021* 年 *9* 月

- 重构 Yalla 聊天室推荐系统，采用多目标优化算法，用户日活跃时长增加 **35%**，7 日留存率从 **42%** 提升至 **61%**，月收入增长 **1200 万**美元。
- 构建 Ludo 智能风控系统，结合实时行为分析和机器学习模型，恶意用户识别准确率达 **94%**，退款率降低 **45%**，挽回损失约 **500 万**美元。
- 开发德州扑克 AI 机器人，基于深度强化学习，胜率达到 **78%**，驱动用户游戏时长增加 **25%**，付费转化率提升 **18%**。

高级算法工程师，格家网络科技
杭州，中国
搜索推荐工程组
2019 年 *3* 月 - *2020* 年 *9* 月

- 设计多场景推荐算法架构，整合协同过滤、深度学习和知识图谱技术，商品点击率 (CTR) 提升 **28%**，转化率 (CVR) 增长 **35%**，GMV 增长 **4200 万**人民币。
- 优化实时推荐引擎，支持 **100 万** QPS 并发，响应延迟控制在 **50ms** 以内，推荐覆盖率达到 **95%**，用户满意度评分从 **3.2** 提升至 **4.6**。

机器学习工程师，便利蜂科技
北京，中国
数据工程组
2017 年 *3* 月 - *2019* 年 *3* 月

- 构建智能销售预测系统，覆盖 **50+** 门店，预测精度达到 **92%**，库存周转率提升 **30%**，减少缺货损失 **600 万**人民币，降低滞销损失 **400 万**人民币。
- 开发用户画像与商品关联分析系统，处理 **1000 万** + 用户行为数据，客户身份识别准确率 **89%**，个性化推荐带来销售增长 **22%**。
- 设计计算机视觉商品识别系统，支持 **500+**SKU 自动识别，识别准确率 **96%**，收银效率提升 **60%**，顾客排队时间减少 **40%**。

本科研究项目

蛋白质分子动力学仿真与 QM/MM 模型
厦门大学，中国
(国家自然科学基金项目)
2014 年 *9* 月 - *2017* 年 *3* 月

- 利用量子力学进行蛋白质动力学仿真研究，分析蛋白质生物信息。涉及理论物理、结构生物学、计算化学和计算机科学等跨学科知识。

液体活检 ct-DNA 试剂盒开发与 DNA 甲基化数据分析
乐普医疗，中国
(研发工程师实习)
2016 年 *3* 月 - *2017* 年 *3* 月

- 从事液体活检试剂盒开发，需要特定的癌症筛查生物标志物。利用现有基因芯片数据 (TCGA&GEO)，分析 10,000 个样本以定位人类 Septin9 基因上的甲基化位点，这是结肠癌的早期指标。这为开发更准确的结肠癌临床诊断试剂盒提供了信息。

获奖情况

- 评委，应用算法最佳实践初审，2021 年。
- 第 57 名和第 32 名，共 1739 队，IEEE ICDM 全球气象 AI 挑战赛，2018 年。
- 一等奖，北美大学生数学建模竞赛，2013 年。
- 第 6 名，国际太阳能十项全能竞赛，2013 年。
- 国家一等奖，全国大学生数学建模竞赛，2012 年。

发表论文

- Cai Y, Su M, Ahmad A, Hu X, Sang J, Kong L, Chen X, Wang C, Shuai J, Han A. Conformational dynamics of the essential sensor histidine kinase WalK. *Acta Crystallographica Section D: Structural Biology*. 2017 Oct 1;73(10):793-803.
- Xia H, Chen X, Chen X, Cheng J, Liu Y, Chen X, Zhang Q, Zou G. Chiral discrimination of amino acid enantiomers based on different interactions with Cu2+. *Sensors and Actuators B: Chemical*. 2018 Jan 1;254:44-51.
- Ahmad A, Cai Y, Chen X, Shuai J, Han A. Conformational dynamics of response regulator RegX3 from Mycobacterium tuberculosis. *PloS one*. 2015 Jul 22;10(7):e0133389.
- Chen Y, Qi H, Li X, Cai M, Chen X, Liu W, Shuai J. Suppressing effect of C a 2+ blips on puff amplitudes by inhibiting channels to prevent recovery. *Physical Review E*. 2016 Aug 15;94(2):022411.