CHEN XINGQIANG

杭州，中国
+86 150-0133-4125 ◇ joy6677@outlook.com ◇ github.com/chenxingqiang

求职意向

寻求**全职**职位：**AI 加速器编译器 / 系统软件 · 大语言模型推理系统 · 软硬件协同设计**。

交叉学科背景

理论物理与生物物理训练，贯通计算化学、分子动力学与计算机科学。竞赛：**全国大学生数学建模竞赛国家一等奖**（2012）、**北美大学生数学建模竞赛（MCM）一等奖**（2013）；**CCF 开源 GPU 创新生态赛 GPU 算子优化挑战赛二等奖**（2025）。

教育背景

生物物理学与凝聚态物理博士研究生（结业，学位答辩中） 2014 年 9 月 - 2018 年 7 月
厦门大学，物理与机电工程学院；导师方向：蛋白质动力学与 QM/MM 仿真

理论物理学学士 2010 年 9 月 - 2014 年 7 月
厦门大学，物理与机电工程学院

技能与项目

编程语言：C++、Python（主要）；CUDA、Java、Scala、Go。

编译器 / 工具链：MLIR、LLVM 后端与 ISA 适配、TVM、图划分与算子融合、成本建模、CodeGen、自动调优。

芯片软件 / 验证：Palladium Emulation、GDB 与仿真模型联调、固件与权重映射生成、算子级指标（Cycles/MACs）分析。

推理系统：Transformers、KV-Cache、量化、批处理与调度、Triton 内核、FlashAttention、CUPTI/Perfetto 性能剖析。

平台：PyTorch、TensorFlow、ONNX、Kubernetes；Spark、Flink、Hadoop。

开源与发布（默认位于 `github.com/chenxingqiang`，均可公开验证）：

- **TraceSmith**：跨平台 GPU Profiling & Replay 系统，覆盖 CUDA/ROCm/Metal/MACA/Ascend；C++ 核心 + Python 绑定，已发布至 PyPI。`TraceSmith`
- **YiRage 持久化内核（YPK）**：LLM 超级内核编译器与运行时，多后端（CUDA/CPU/MPS/Ascend/Triton）。`YiRage`
- **JAX-sklearn**：scikit-learn 兼容接口 + JAX 加速，13,058 项测试通过，PyPI 发布。`jax-sklearn`
- **Secret-Learn**：隐私保护机器学习库，覆盖联邦学习／秘密分享／分割学习，PyPI 发布。`Secret-Learn`
- **YouTube-DNN-RecSys**：YouTube 风格召回与排序的 TensorFlow + Spark 实现（60 stars）。`YouTube-DNN-RecSys`
- **Research CLI**：面向科研工作流的命令行 AI 工具，多模型供应商与 MCP 集成。`iechor-research/research-cli`
- **Questions-Gen**：数学竞赛题目生成（Qwen3-14B、GRPO、蒸馏），含 CLI 与 Hugging Face 权重。`GenQuestion`

工作经历

编译器 & 工具链专家，知存算力（Witmem） 杭州，中国
编译器 / *Palladium* 验证 *2025* 年 *12* 月 *10* 日 - 至今

- 负责存算芯片产品线编译器与 Palladium 仿真验证，覆盖模型编译、指令生成、芯片执行及 Emulation 缺陷定位。
- 完成 Palladium 软件 Bring-up：Compiler 输出在仿真器上运行，结合 GDB 在仿真模型、芯片与系统软件层做联合调试。
- 实现 **CIM-MLIR** 异构编译器：PyTorch/TensorFlow/ONNX 经 TOSA/StableHLO 映射至 CPU、GPU 与 CIM，含前端、图划分、硬件后端与运行时。
- 实现代价驱动图划分与 CIMHigh/Mid/Low 三级 IR；用 OR-Tools 分配 Die/L2/L0 资源，生成可烧录 **config.bin**、权重 **map.bin**，以及 GPU PTX 与 LLVM 主机代码。

- 实现跨设备运行时：分设备执行器、统一内存、计算与传输重叠及三级缓冲；提供 C++/Python 接口及延迟、利用率、传输开销统计。
- 实现 **GRC-PIM**：PIM 上基于 drift gating 与 GEMV 复用的残差校准及软判决纠错，投稿 *npj Unconventional Computing*（详见发表论文）。

高级 AI 编译器工程师，亿铸智能
杭州，中国

研发部门 *2022* 年 *9* 月 - *2025* 年 *12* 月

- 主导 **YiRage 持久化内核 (YPK)**：将端到端 LLM 解码编译为单个超级内核；在 Llama2-7B、单卡 A100 上相对 PyTorch eager 基线取得 **1.2×–6.7×** 端到端延迟收益（随 batch 与序列长度变化）。YiRage
- 实现融合算子（RMSNorm+Linear、GQA 等）与持久化执行模型，显著减少内核启动与中间张量往返；batch=1 decode 路径延迟降幅最大。
- 构建调度层并集成 Triton 与 FlashInfer 内核，支持多卡扩展（最高验证 8 卡）与 NVSHMEM 张量。
- 开发图编译与自动调优：内核参数搜索、KV-cache 友好内存布局，降低访存开销。
- 申请 **2 项**发明专利；相关能力交付 **2 个**数据中心客户 PoC。
- 负责公司 SoC 的 LLVM 后端 Target 与复杂指令集适配，推进编译器后端规范化与软件生态建设。
- 搭建模型转换与算子级评估流程：将 TVM、ONNX、MLCommons、TensorFlow/PyTorch 集成入 **YZlite**，统计 Cycles/MACs 等指标并输出多芯片 benchmark；开源工具包与文档 ReRAM-Labs/yzlite。

隐私保护算法工程师，蓝象智联
杭州，中国

IT Group *2022* 年 *1* 月 - *2022* 年 *9* 月

- 构建基于同态加密的联邦学习平台，支撑多家金融机构的跨域建模；在保持隐私约束下相对本地基线提升模型效果，并缩短训练迭代周期。
- 设计多方安全计算协议，用于银行风控模型的联合训练与推理，兼顾协议安全性与通信开销。
- 开源 **Secret-Learn**：sklearn 兼容 API × 联邦学习／秘密分享／分割学习三种模式，JAX 加速，并与 SecretFlow 集成，PyPI 发布。Secret-Learn
- 申请 **3 项**发明专利（均已公开，可检索）：基于秘密分享的纵向联邦线性支持向量分类方法 CN114925786A；随机森林训练方法及装置 CN114997345A；用于联邦学习的数据处理方法及装置 CN115130681A。

T7 算法工程专家，百图生科
北京，中国

算法工程组 *2021* 年 *9* 月 - *2021* 年 *12* 月

- 构建生物信息学工具链与数据平台，统一大规模生物数据的管理、检索与分析流程，支撑序列分析、结构预测与功能注释。
- 搭建蛋白质结构预测模型评估流程（含 AlphaFold 系列），为药物设计提供结构输入。
- 获 **2 项**软件著作权：生信工具自动化平台（登记号 2021SR2004464）、生物医药信息平台（登记号 2021SR1862397）。
- 开源 AlphaFold2 代码解析与学习资源（26 stars）。alphafold2-codecs

高级算法工程师，Yalla 集团 (纽交所: YALA)
杭州，中国

数据中心工程组 *2020* 年 *9* 月 - *2021* 年 *9* 月

- 重构 Yalla 聊天室推荐系统，引入多目标排序；A/B 实验中人均日活跃时长与 7 日留存均取得显著正向（留存 **42%** → **61%**）。
- 构建 Ludo 风控系统，结合实时行为特征与机器学习模型识别异常账号，显著降低恶意退款比例。
- 开发卡牌类游戏 AI（深度强化学习），用于人机对局与匹配填充，提升低峰时段对局体验与留存。

高级算法工程师，格家网络科技
杭州，中国

搜索推荐工程组 *2019* 年 *3* 月 - *2020* 年 *9* 月

- 设计多场景推荐架构，融合协同过滤、深度排序模型与商品知识图谱；线上实验 CTR 与 CVR 均取得两位数相对提升。
- 优化实时推荐链路：特征缓存与召回裁剪，P99 响应控制在 **50ms** 内，支撑大促期间峰值流量。
- 开源 YouTube-DNN-RecSys：YouTube 风格召回与排序的 TensorFlow + Spark 实现（60 stars）。YouTube-DNN-RecSys

机器学习工程师，便利蜂科技
北京，中国

数据工程组 *2017* 年 *3* 月 - *2019* 年 *3* 月

- 构建门店销量预测系统（覆盖 **50+** 门店），引入格点气象与时空特征，降低缺货与滞销率、提升库存周转。
- 开发用户与商品关联分析：在千万级行为数据上打通客户身份与购买记录，支撑个性化推荐。
- 设计商品视觉识别模型（**500+** SKU），用于快速结算场景，缩短收银与排队时间。

研究与实习

蛋白质分子动力学仿真与 QM/MM 模型
厦门大学，中国
(国家自然科学基金项目) *2014* 年 *9* 月 - *2017* 年 *3* 月

- 以 QM/MM 方法开展蛋白质动力学仿真与构象分析，成果发表于 Acta Cryst. D、PLoS ONE、Phys. Rev. E 等（见发表论文）。

液体活检 ct-DNA 试剂盒开发与 DNA 甲基化数据分析
乐普医疗，中国
(研发工程师实习) *2016* 年 *3* 月 - *2017* 年 *3* 月

- 在 TCGA/GEO 公开基因芯片数据上分析约 10,000 例样本，定位 Septin9 基因甲基化位点（结肠癌早期标志物），支撑临床诊断试剂盒的标志物筛选。

获奖与评审

- **国家一等奖**，全国大学生数学建模竞赛（CUMCM），2012 年。
- **一等奖**（Meritorious Winner），北美大学生数学建模竞赛（MCM/COMAP），2013 年。
- 全球**第 6 名**，国际太阳能十项全能竞赛（Solar Decathlon），2013 年。
- 第 **57** 名与第 **32** 名（共 1739 队），IEEE ICDM 全球气象 AI 挑战赛，2018 年。
- **二等奖**，第八届 CCF 开源创新大赛・开源 GPU 创新生态赛常规赛 S1 ・GPU 算子优化挑战赛（CCF/ODTC），2025 年。CCF 公示
- 评委，应用算法最佳实践初审，2021 年。

发表论文

- Chen X. GRC-PIM: A Drift-Gated, GEMV-Reusing Residual Calibrator for Soft-Decision Error Correction in Processing-in-Memory. *npj Unconventional Computing*（投稿中）。
- Cai Y, Su M, Ahmad A, Hu X, Sang J, Kong L, Chen X, Wang C, Shuai J, Han A. Conformational dynamics of the essential sensor histidine kinase WalK. *Acta Crystallographica Section D: Structural Biology*. 2017 Oct 1;73(10):793-803.
- Xia H, Chen X, Chen X, Cheng J, Liu Y, Chen X, Zhang Q, Zou G. Chiral discrimination of amino acid enantiomers based on different interactions with Cu2+. *Sensors and Actuators B: Chemical*. 2018 Jan 1;254:44-51.
- Ahmad A, Cai Y, Chen X, Shuai J, Han A. Conformational dynamics of response regulator RegX3 from Mycobacterium tuberculosis. *PloS one*. 2015 Jul 22;10(7):e0133389.
- Chen Y, Qi H, Li X, Cai M, Chen X, Liu W, Shuai J. Suppressing effect of C a 2+ blips on puff amplitudes by inhibiting channels to prevent recovery. *Physical Review E*. 2016 Aug 15;94(2):022411.

Open Source Architecture Appendix

Chen Xingqiang · github.com/chenxingqiang · zone-based end-to-end system architecture

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

CONTENTS · one architecture per page

TraceSmith
GPU profiling & replay

YiRage
RuntimeFusion compiler

JAX-sklearn
transparent JAX acceleration

Secret-Learn
privacy-preserving ML

YouTube-DNN
two-tower recall

Research CLI
agent workflow

Questions-Gen
three-stage training

阅读约定

自上而下读取主数据流；虚线框表示架构分区；盒内仅列模块与职责。

蓝色实线表示主链路，紫色虚线表示回退或反馈，不以源码文件充当架构层。

TraceSmith — 系统架构 · GPU Trace 端到端数据流

Application → bindings → capture / state / format → replay & export → GPU backends

主数据流　虚线框 = 架构分区
回退 / 反馈　盒内 = 模块 + 职责

APPLICATION · 用户入口

C++ / Python Application
嵌入业务进程

CLI
profile · record · view · export

External UI
Perfetto · Chrome

BINDINGS · Python / C++ 边界

_tracesmith.so
pybind11 native extension

CORE LIBRARY · C++17

Capture Module
CUPTIProfiler · MCPTIProfiler
Metal · Ascend · ROCm · eBPF

Common + Format
RingBuffer SPSC · StackCapture
SBTWriter / SBTReader

State Module
GPUStateMachine
TimelineBuilder · PerfettoExporter

Replay Module
ReplayEngine · StreamScheduler
DeterminismChecker · FrameCapture

CROSS-CUTTING · 集群与调试

replay / debug feedback

Cluster Module
GPUTopology · TimeSync
NCCLTracker

GDB / Tracy
RSPHandler · GPUDebugEngine
TracyExporter

GPU BACKENDS · 系统接口

NVIDIA
CUDA · CUPTI · nsys

MetaX
MACA · MCPTI · mcTracer

Apple / AMD
Metal · xctrace · ROCm

Huawei / Linux
CANN · msprof · eBPF

OUTPUTS · Trace 产物

trace.sbt
compact binary

trace.json / .perfetto
Perfetto timeline

graph.dot / ASCII
analysis views

主链：GPU event → lock-free ring → SBT/state → replay 或 Perfetto；Cluster / GDB 为旁路能力。

YiRage (YPK) — 系统架构 · RuntimeFusion 数据流

Inference engine owns scheduling/KV; RF owns fusion identity; search and execute use the same backend

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

INFERENCE ENGINE · 调度与 KV 所有者

vLLM
continuous batch · PagedAttention

SGLang
RadixAttention · extend meta

Decode Metadata
block table · seq lens · SM budget

RUNTIMEFUSION · 每个 decode step

RF.step(inputs, meta)
select 0..N capsules

FusionCapsule
MLP gate_up + down
segment pipeline

Native Fallback
skip → engine native ops

SEARCH & PLAN · offline / warm-up

superoptimize(backend)
KN / TB graph search

FusionPlan / μGraph
profile · fingerprint verify

Persistent Cache
shape bucket restore

Ray Coordinator
optional distributed search

fallback / re-search

BACKEND MANAGER · 编译与执行边界

BackendRegistry
search + execute same backend

KNGraph / TBGraph
transpiler → kernels

yirage.core
Cython runtime

BACKENDS → HARDWARE

CUDA / MACA
NVIDIA GPU · MetaX C500/C550

ROCm / MPS
AMD GPU · Apple Silicon

Ascend / NKI
Huawei 910 · AWS Neuron

CPU / MLIR / Triton
x86 · ARM · extra targets

主链：Engine metadata → RF.step → FusionCapsule → BackendRegistry → target hardware。

JAX-sklearn (xlearn) — 五层架构 · 透明加速数据流

100% sklearn API → runtime injection → proxy dispatch → array conversion → JAX hardware

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

USER CODE · sklearn-compatible API

import xlearn as sklearn
LinearRegression · KMeans · PCA

Estimator Calls
fit · predict · transform

COMPATIBILITY · xlearn/__init__.py

__getattr__
lazy module loading

_auto_jax_accelerate_module
runtime class injection

AcceleratorRegistry
algorithm implementation map

JAX ACCELERATION · xlearn/_jax

EstimatorProxy
fit-time dispatch

Universal JAX
JIT · vmap · accelerated estimator

sklearn Fallback
original estimator

graceful fallback

DATA MANAGEMENT · boundary conversion

NumPy → JAX
dtype · shape normalization

Policy / Thresholds
dataset size · platform · config

JAX → NumPy
sklearn-compatible outputs

HARDWARE ABSTRACTION · JAX backend

CPU
jaxlib

CUDA GPU
JAX XLA

TPU
JAX XLA

Apple Metal
experimental

代理根据算法、数据规模和配置选择 JAX；不满足条件或执行失败时回退原生 sklearn。

Secret-Learn — 六层架构 · 隐私计算数据流

sklearn-compatible API → privacy mode → JAX / SecretFlow compute → secure devices

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

APPLICATION · 多方隐私数据

Healthcare / Finance
cross-party modeling

IoT / Research
distributed learning

SKLEARN API · 统一算法入口

secretlearn.*
fit · predict · transform

algorithm_classifier.py
classify fit signature / epochs

PRIVACY MODES · execution placement

FEDERATED LEARNING
PYU local compute
HEU secure aggregation

SECRET SHARING
SPU MPC · ABY3 / CHEETAH

SPLIT LEARNING
split model · encrypted activations

ACCELERATION & COMPUTE

JAX Acceleration
JIT · vmap · xlearn

SecretFlow Runtime
party orchestration

SECURE DEVICES

PYU
party-local plaintext

HEU
homomorphic aggregation

SPU
secure MPC

TEE
optional enclave

INFRASTRUCTURE & HARDWARE

SecretFlow
distributed secure runtime

JAX / XLA
CPU · GPU · TPU

sklearn
API compatibility

同一 sklearn 调用由 FL / SS / SL 决定数据驻留与执行设备；JAX 加速可公开的本地计算。

YouTube-DNN-RecSys — 系统架构 · 召回数据流

Python / Spark data preparation → TFRecords → dnn.py → user & item vectors → prediction

主数据流　　虚线框 = 架构分区

回退 / 反馈　　盒内 = 模块 + 职责

DATA PROCESSING · 离线样本构建

Python Pipeline
data2tfrecords.py
read_tfrecords.py

Spark Pipeline
MakeDataOne.scala
MakeDataTwo.scala

FeatureBuilder
history + continuous features

STORAGE · 训练与模型产物

TFRecords
train / evaluation

Checkpoints
ckpt / eval / modelpath

MODEL TRAINING · src/python/models/dnn.py

Input
visit_items_index × 5
continuous_features × 16

Item Embedding
500 × 16 · average pooling

User Tower
Dense 64 → 32 → vector 16

Softmax Output
500 classes · Top-K

evaluation feedback

PREDICTION · serving paths

Python SavedModel
load_dnn_model.py

User Vector
PredictUserVector.scala

Item Table
ItemEmbeddingPredictor.scala

RECOMMENDATION OUTPUT

Candidate Recall
user vector × item embedding

Top-K Items
next-item recommendation

主链：行为历史 → TFRecords → embedding mean-pool → user vector → item table matching → Top-K。

Research CLI — 系统架构 · Agent 请求数据流

Terminal UI → core orchestration & routing → tools / MCP / research modules → model providers

主数据流　回退 / 反馈　虚线框 = 架构分区　盒内 = 模块 + 职责

CLI FRONTEND · packages/cli

Interactive TUI
research.tsx · sessions

Commands
mcp · skills · hooks

ACP
acpSession.ts

CORE ORCHESTRATION · packages/core

Context & Memory
config.ts · memory.ts

modelRouterService
provider selection

Routing Strategy
default · classifier · approval

TOOLS & INTEGRATIONS

Workspace Tools
filesystem · shell

MCP
external service adapters

Research Modules
writing · bibliography · analysis

SDK / A2A / VS Code
embedded clients

tool result loop

MODEL PROVIDERS · provider config

Gemini / Vertex
hosted models

OpenAI / Anthropic
hosted models

Baidu / DeepSeek / Qwen
hosted models

RESULT STREAM

Tool Results
structured observations

Assistant Response
streamed to terminal

主链：prompt → packages/cli → packages/core router → provider / tools → structured result → terminal。

Questions-Gen — 系统架构 · 三阶段训练数据流

Training data → SFT → GRPO → DeepSeek distillation → validation → Hugging Face / Ollama

主数据流　　虚线框 = 架构分区
回退 / 反馈　　盒内 = 模块 + 职责

TRAINING DATA · problem mixture

Historical Problems
50% source distribution

Variants
30% conditional variation

Novel Problems
20% innovation target

Stage 1 SFT · QuestionsGenTrainer.py

Qwen3-14B
supervised fine-tuning

Stage-1 Checkpoint
stage1-fp-merged

Stage 2 GRPO · reward optimization

RewardCalculator
0.4 difficulty · 0.3 novelty
0.2 rigor · 0.1 diversity

NoveltyConstraint
variation / duplication guard

GRPO Trainer
group-relative optimization

Stage 3 Distill · teacher supervision

quality feedback

DeepSeekTeacher
DeepSeek-R1 reasoning teacher

Final Model
final-merged-16bit

VALIDATION

ModelValidator
single checkpoint

BatchValidator
algebra · geometry · calculus

QualityEvaluator
clarity · difficulty · originality

DEPLOYMENT

Hugging Face
three published stages

Ollama
local inference

questions-gen CLI
validate · batch · quality

主链：混合题库 → SFT → GRPO reward/novelty → DeepSeek-R1 distill → validate → publish。